

# Detección de anomalías en pacientes hospitalarios con el dataset MIMIC III

Isaac Esteban Uribe Jaramillo

Ingeniería, Universidad de Antioquia, Medellín, Antioquia, Colombia;

Correo: isaac.uribej@udea.edu.co

7 Keywords: vital signs prediction, anomaly detection, patient monitoring, early warnings

8 Abstract

9 Proporcionar una intervención temprana y un trato humano debe ser una prioridad en el servicio  
10 médico. Por eso, ofrecer métodos y herramientas analíticas que apoyen al personal sanitario es  
11 clave para mejorar la atención en hospitales y UCI. Este estudio usó la base de datos MIMIC-III  
12 para analizar signos vitales clave: frecuencia cardíaca, saturación de oxígeno, temperatura y  
13 presión arterial. Se filtró y preprocesó un conjunto grande de datos, organizándolo  
14 cronológicamente por paciente y muestra. Se creó una etiqueta artificial “PATIENT\_STATE” para  
15 clasificar los registros en normal, taquicardia o bradicardia. Con técnicas de limpieza e imputación  
16 KNN, el dataset final tuvo 72,922 registros.

17 El análisis mostró distribuciones similares entre grupos y una fuerte correlación esperada entre  
18 presiones sistólica y diastólica. La detección con Factor Local Outlier identificó anomalías clínicas  
19 realistas en glucosa y temperatura, captando detalles que otros métodos simples no detectaban.  
20 Aun hace falta mejorar tanto calidad y análisis de datos, este enfoque promete alertar  
21 oportunamente sobre condiciones críticas, que podría brindar una monitorización más inteligente y  
22 automatizada, lo cual, puede reducir costos hospitalarios al prevenir complicaciones durante los  
23 ingresos.

24    **1. Introducción**

25    En un contexto clínico la detección de mediciones anómalas en signos vitales o análisis clínicos  
26    es de un interés valioso en el área médica, pues con la detección temprana de signos vitales que  
27    superen los rangos normales, se puede generar una alerta para informar a los profesionales de la  
28    salud sobre posibles deterioros en el estado del paciente, pues si diéramos tratamiento pacientes  
29    sin determinar sus signos vitales, es posible que no reflejemos la urgencia de su situación [1]. El  
30    grado de anomalías y las patologías presentes en un paciente cuando es ingresado también nos  
31    puede suministrar información de cuál debería ser el comportamiento de sus demás signos vitales,  
32    como la evolución de este.

33    El combinar métodos de análisis y predicción resulta importante pues esto permite el manejo de  
34    recursos de una manera más efectiva, la atención temprana y un trato más humano por parte del  
35    personal médico. Además, las ventajas que ofrecen las implementaciones de monitoreo de signos  
36    vitales con modelos predictivos, posibilitan las intervenciones oportunas, que pueden tener un alto  
37    impacto en el diagnóstico y la prevención de enfermedades y complicaciones durante los ingresos  
38    hospitalarios [2]. Esto también reduce los costos hospitalarios al disminuir la necesidad de  
39    tratamientos innecesarios y ayudar a remediar problemas en futuros reingresos. De esta manera,  
40    estos modelos permitirán personalizar el cuidado según las necesidades específicas de cada  
41    paciente.

42    Según el protocolo de monitoreo no invasivo de signos vitales de la clínica Sagrado Corazón, “*La  
43    temperatura, la respiración, la frecuencia cardiaca, la saturación, la tensión arterial y la  
44    frecuencia cardiaca fetal, son parámetros a través de los cuales es posible evaluar el estado  
45    hemodinámico de la salud de un individuo, pues sus valores se mantienen constantes dentro de  
46    ciertos límites, en estado de normalidad*” [3], evidenciando que mantener un monitoreo constante  
47    y preciso de estos parámetros es fundamental para detectar cualquier desviación que pueda indicar  
48    un deterioro en la salud del paciente, además aportando una visión objetiva de cuáles marcas se  
49    deberían tener presentes para el análisis oportuno del estado de un paciente, siendo su temperatura  
50    corporal, su frecuencia cardiaca y porcentaje de oxígeno en la sangre características fundamentales  
51    en la predicción del estado y la predicción de este; por lo tanto, la medición precisa de estos signos  
52    requiere práctica y tiempo, lo que presenta una limitación importante en los métodos tradicionales  
53    de monitoreo clínico. Además, el monitoreo constante de todos los pacientes que es una tarea casi  
54    imposible por la limitación del personal médico disponible para la atención de muchos pacientes.

55    Estas restricciones introducen la necesidad de desarrollar nuevas técnicas y tecnologías que  
56    permitan el monitoreo automatizado, la predicción y el apoyo en la evaluación del estado de salud  
57    de un paciente. La incorporación del análisis de datos ayudará a solventar las problemáticas  
58    derivadas de los métodos convencionales y proporcionará soporte en el análisis de datos y  
59    tendencias médicas. Mediante técnicas de imputación, limpieza y tratamiento de datos de pacientes  
60    reales, se intentará sistematizar la detección de datos anómalos en pacientes con indicios o  
61    diagnóstico de taquicardia o bradicardia, conceptos definidos en el protocolo de monitoreo [3][4]

62 como trastornos o alteraciones en el ritmo cardíaco por encima de 100 bpm y por debajo de 60  
63 bpm, respectivamente. Con estas etiquetas se busca llevar a cabo labores de análisis clínico para  
64 entender cómo se correlacionan los signos vitales y cómo estos explican comportamientos  
65 anómalos en pacientes con determinadas condiciones.

66

67 **2. Metodología**

68 En primera instancia se adquirió la base de datos MIMIC-III para el desarrollo de esta actividad.  
69 Se revisaron los archivos que forman parte del compendio suministrado junto con el dataset, en  
70 particular el archivo CHARTEVENTS.csv, que contiene varias columnas, entre ellas un  
71 identificador único para cada dato tomado a un paciente. Este identificador está asociado a un  
72 código que especifica qué signo vital fue medido en cada registro.

73 En base a esta información se realizó un filtrado y una preselección de los signos vitales relevantes  
74 para el análisis, decidiendo trabajar únicamente con la información contenida en el archivo  
75 CHARTEVENTS.csv y se acotó a seleccionar signos vitales. Esto se hizo para evitar la  
76 complejidad de manejar y concatenar información dispersa en varios archivos, lo cual complicaría  
77 el pre-procesamiento y procesamiento de datos.

78 **Proceso de acotamiento y preparación del dataset:**

79 Debido al gran tamaño del dataset original de MIMIC-III, fue necesario realizar un proceso de  
80 acotamiento y preparación para hacer los datos manejables para este análisis. El archivo contiene  
81 una columna con los valores de las mediciones de los biomarcadores y otra con el identificador o  
82 código que especifica el tipo de biomarcador (Ritmo cardíaco, saturación de oxígeno, temperatura  
83 corporal, glucosa, presión sistólica y presión diastólica).

84

85 Para trabajar con las variables de forma individual, se siguió el siguiente procedimiento:

- 86 • **Procesamiento por biomarcador:** Se procesó el dataset original en fragmentos (chunks)  
87 para controlar el volumen y evitar sobrecarga de memoria.
- 88 • **Filtrado por código:** En cada fragmento se seleccionaron únicamente los biomarcadores  
89 de interés, identificados por sus códigos únicos.
- 90 • **Extracción y almacenamiento:** Los datos filtrados para cada biomarcador se extrajeron y  
91 guardaron en archivos CSV separados.
- 92 • **Ensamblaje del dataset final:** Posteriormente, los datos extraídos de cada biomarcador  
93 fueron combinados en un único DataFrame.
- 94 • **Organización cronológica:** Finalmente, el dataset ensamblado se ordenó por la fecha y  
95 hora de toma de muestra (CHARTTIME), para asegurar un análisis temporal preciso de la

96 evolución de los biomarcadores, ademas se ordeno por paciente los cuales tienen un "id"  
97 unico asociado a ellos.

98  
99 El dataset original contaba con 9028427 entradas, pero se decidió reducirlo a 100.000 registros  
100 para que el procesamiento no fuera tan pesado y no llevara mucho tiempo a la hora correr los  
101 notebooks. Posteriormente con el fin de acotar el problema, se creó una variable objetivo o variable  
102 de observabilidad, para dar más explicabilidad a los datos y haremos uso de una función para crear  
103 esta columna con una "etiqueta artificial" (PATIENT\_STATE) que representa el estado clínico  
104 estimado del paciente durante la remisión o ingreso hospitalario. Esta etiqueta busca reflejar si el  
105 ingreso fue normal o si el paciente parecía presentar o si se sospechaba que podía tener alguna  
106 condición crítica según sus signos vitales.

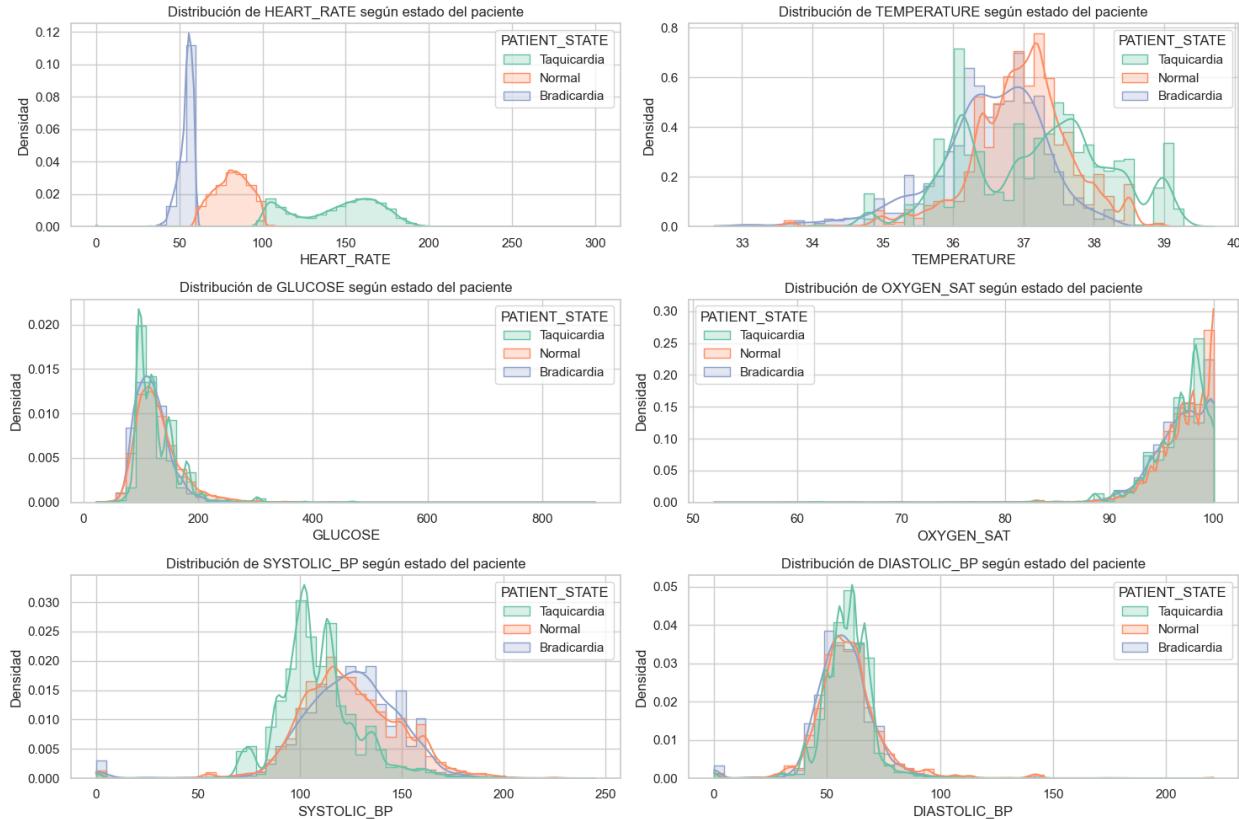
107 La función asigna el estado clínico a cada registro en base a umbrales clínicos comúnmente  
108 aceptados.[3] de esta manera pues se clasificó la población en 3 clases pacientes con:  
109 "Taquicardia", "Braquicardia" y "**Normal**", con los cuales se procedió a hacer un análisis  
110 exploratorio con el cual se empezó por consultar el desbalance de las clases, de los cuales se podía  
111 observar que el 63.27% de las mediciones de pacientes presentaba un estado Normal en su ritmo  
112 cardíaco durante su ingreso hospitalario, un 33.84% de las mediciones correspondían a un aumento  
113 del ritmo cardíaco y solo un 2.89% eran registros asociados a una disminución del mismo.

114 Se hizo primero una normalización en los datos de temperatura que presentaban valores con  
115 mediciones extremas con temperaturas superiores a 100°, se concluyó que probablemente  
116 estuvieran en grados Fahrenheit que es una unidad de medida común en EEUU y se decidió  
117 transformarlo usando la fórmula (1)

$$^{\circ}C = (^{\circ}F - 32) \times \frac{5}{9} \quad (1)$$

118  
119 Después se realizó un análisis de la distribución de los datos para cada una de las categorías  
120 acotadas anteriormente, efectuando un análisis univariado para cada variable involucrada en el  
121 problema. Se encontraron distribuciones similares con ligeros cambios entre las categorías.  
122 Adicionalmente, el análisis multivariado exploró la correlación entre variables, encontrándose una  
123 correlación fuerte únicamente entre la presión sistólica y la presión diastólica, lo cual es esperable  
124 dado que ambas representan medidas relacionadas del ciclo cardíaco: la presión sistólica  
125 corresponde a la fuerza con la que el corazón bombea la sangre, mientras que la diastólica es la  
126 presión cuando el corazón está en reposo, lo que refleja la resistencia vascular y la elasticidad  
127 arterial. Esta relación fisiológica intrínseca explica la alta correlación observada entre ambas  
128 variables.[5]

129 Se exploraron técnicas como la detección de datos atípicos con las técnicas de IQR y Z-Score en  
130 la cual destaca el IQR en el contexto de detectar o acotar secciones de atípicos que se ajustan a las  
131 necesidades de este problema.



132

133

Figura 1. Distribucion de datos por categoria por signo vital

134

135 Pero el dataset presenta carencias como algunas secciones carentes de datos por lo cual para  
 136 normalizar y estandarizar el dataset y dar tratamiento a los datos faltantes se decidió hacer un  
 137 trabajo de limpieza, se empezó por estandarizar el formato de datos los cuales tuvieran registros  
 138 tipo calendario para asegurar que la columna CHARTTIME esté en formato datetime  
 139 “DD:MM:AA HH:MM:SS:MS”, en esta etapa se implementa métodos para agrupar y llenar  
 140 usando técnicas de backward y forward evitar NaN dentro de misma hora.

141 También se definen umbrales mínimos aceptables para algunas variables fisiológicas, con el  
 142 objetivo de eliminar registros que, por su valor, representarían condiciones incompatibles con la  
 143 vida o errores de medición evidentes. Para la temperatura corporal, de acuerdo con fuentes  
 144 médicas, se considera que el cuerpo humano entra en un estado de hipotermia cuando la  
 145 temperatura central desciende por debajo de los 35 °C. Temperaturas menores a este valor  
 146 comprometen de manera crítica las funciones vitales, y valores inferiores a 20 °C serían  
 147 prácticamente incompatibles con la vida [6]. Por este motivo, se eliminarán los registros con  
 148 valores de TEMPERATURA menores a 20 °C, asumiendo que representan errores instrumentales  
 149 o mediciones atípicas no fisiológicas. Para la saturación de oxígeno; según la literatura médica,  
 150 una saturación de oxígeno por debajo de 90 % se considera un signo de hipoxemia, lo que indica

151 niveles insuficientes de oxígeno en la sangre y, en casos prolongados, puede ser potencialmente  
152 letal. [7] Por lo tanto, se establece un umbral mínimo de 50 % para esta variable, eliminando  
153 cualquier registro con valores inferiores a dicho límite.

154 En conjunto, estos criterios permiten mantener únicamente observaciones que representen  
155 condiciones fisiológicas realistas, evitando que datos erróneos que afecten las siguientes etapas del  
156 análisis.

157 Para la imputacion de datos faltantes y en vista de que el mecanismo de ausencia corresponde a un  
158 MAR (Missing At Random) como se vio en la literatura de tipos de problemas en datos faltantes  
159 [8], no se eliminan las variables con alta proporción de valores faltantes, como TEMPERATURE,  
160 ya que presentan relevancia fisiológica en la interpretación de los signos vitales (por ejemplo, el  
161 aumento de temperatura suele correlacionar con el incremento del ritmo cardíaco)[8]. En lugar de  
162 ello, se implementa una imputación mediante el algoritmo KNN (K-Nearest Neighbors Imputer),  
163 que estima los valores faltantes a partir de pacientes con características fisiológicas similares.

164 Este método tiene la ventaja de preservar las relaciones multivariadas entre los biomarcadores,  
165 reduciendo el sesgo introducido por imputaciones simples como la media o la mediana.

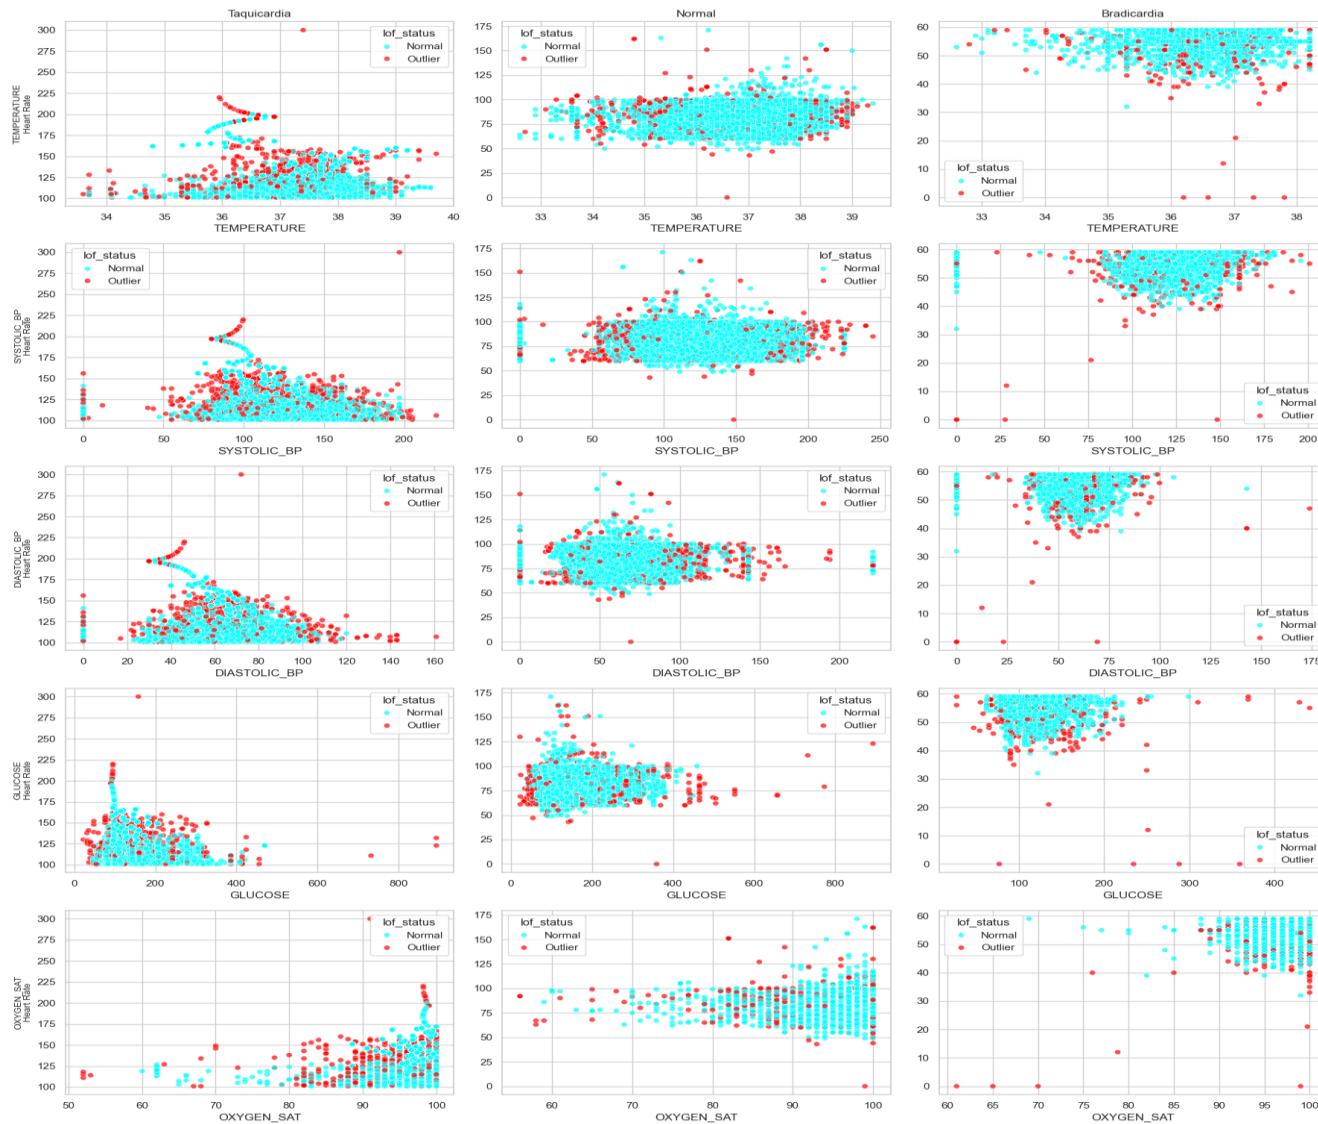
166 Con esto dimos finalizado la limpieza e imputacion de datos faltantes, quedando 72922 registros  
167 de los 100.000 acotados anteriormente; con esto se pudo dar rienda suelta al analisis de signos  
168 vitales por categoria y se encontro ciertas relaciones interesantes que notamos con el coeficiente  
169 de Spearman como unarelacion medianamente debil inversa entre la frecuencia cardiaca y la  
170 presion sistolica, lo cual puede explicarse por el reflejo barorreceptor, un mecanismo fisiológico  
171 mediante el cual el cuerpo regula la frecuencia cardíaca ante variaciones en la presión arterial,  
172 buscando mantener la estabilidad hemodinámica. [9] Se conserve tambien la correlación moderada  
173 entre la presión sistólica y la diastólica,

174 Por otro lado, la temperatura corporal presenta una correlación negativa débil con la saturación de  
175 oxígeno, lo que puede tener una explicación fisiológica relacionada con el efecto Bohr, en el que  
176 el aumento de la temperatura corporal disminuye la afinidad de la hemoglobina por el oxígeno,  
177 reduciendo ligeramente la saturación [10]

178 Finalmente se aplico una estrategia de deteccion de valores atipicos el cual era el objetivo principal  
179 de este Proyecto, para esto se uso Local Outlier Factor (LoF) y la aplicamos a cada una de las  
180 categorias con sus respectivas caracteristicas como se puede evidenciar en parte de la Figura 2

Figura 2. Detección de outliers con LoF

Outliers detectados con LOF — HR vs otros biomarcadores por tipo de paciente



183

184 La tecnica LoF logra identificar varios valores que se desvian de los rangos fisiológicos esperados.  
185 En particular, en las variables de glucosa se destacan puntos con niveles significativamente altos,  
186 lo cual tiene sentido clínico, pues concentraciones elevadas de glucosa en sangre suelen  
187 considerarse anómalas en cualquier estado fisiológico. De igual forma, en la temperatura corporal,  
188 especialmente dentro de los grupos Normal y Bradicardia, se observan detecciones de outliers en  
189 valores alejados del rango corporal normal (aproximadamente entre 37,5 °C y 39,5 °C), lo que  
190 indica que es capaz de captar desviaciones térmicas extremas de manera coherente.

191

### 192 **3. Results and Discussion**

193 Al realizar un análisis exploratorio sobre la distribución de los signos vitales seleccionados, se  
194 encontro que las variables presentaban distribuciones similares entre las categorías “Normal”,  
195 “Taquicardia” y “Bradycardia”, con ligeras variaciones. En el análisis multivariado, solo se detectó  
196 una correlación fuerte entre la presión sistólica y la presión diastólica, coherente con la relación  
197 fisiológica entre ambas presiones como fases del ciclo cardiaco.

198 Para la detección de valores atípicos, al aplicar técnicas como el rango intercuartílico (IQR), Z-  
199 Score y el método Local Outlier Factor (LoF), entre estas LoF destacó por su capacidad para  
200 identificar anomalías consistentes aun que aun algo limitadas en la identificación de varios grupos  
201 o subgrupos de outliers locales, el IQR demostró ser una Buena tecnica para detectar outliers aun  
202 que esta depende un poco mas del contexto y la calidad de los datos.

203 Se evidenciaron carencias en la calidad de los datos, con secciones incompletas o con valores  
204 faltantes que requirieron procesos de limpieza e imputación basados en técnicas de KNN para  
205 preservar relaciones fisiológicas entre variables.

206 Los resultados muestran que la metodología aplicada es una buena aproximación para la detección  
207 de outliers en signos vitales, permitiendo identificar desviaciones significativas que pueden alertar  
208 sobre condiciones clínicas críticas. No obstante, se reconoce la necesidad de mejorar las técnicas  
209 de limpieza y manipulación de datos para optimizar la precisión del análisis. Por otro lado, es  
210 critico contar con datos de mejor calidad y que incluyan todas las mediciones asociadas a los  
211 diferentes signos vitales para robustecer los modelos predictivos futuros.

212 Asimismo, se sugiere explorar nuevas técnicas y considerar correlaciones adicionales entre  
213 etiquetas específicas para grupos particulares de pacientes, de modo que el análisis sea más  
214 contextualizado y clínicamente relevante, al tener un análisis mas robusto.

215

216

217 **4. Conclusiones**

218

219 El monitoreo de signos vitales mediante modelos predictivos sera una herramienta muy útil para  
220 detectar a tiempo posibles problemas en pacientes, lo cual mejorara la atención hospitalaria y  
221 apoyara al personal de la salud reduciendo la carga y el estres en ambientes clinicos. Aunque las  
222 técnicas aplicadas funcionaron bien para identificar datos anómalos, todavía hay margen para  
223 mejorar la limpieza y el análisis de los datos para hacer modelos más precisos. Aun que se  
224 observaron patrones consistentes, como la fuerte correlación entre la presión sistólica y la  
225 diastólica,se debe mejorar y contar con un mejor dataset para que los resultados sean mas precisos  
226 y hechos a medida pues hubo limitaciones y se cree que se pudo llegar a mejores resultados de  
227 tener menos datos faltantes.

228 En resumen, este trabajo representa un paso importante hacia una monitorización más inteligente  
229 y automatizada, que puede ayudar a prevenir complicaciones y reducir costos hospitalarios.  
230 Además, se recomienda seguir perfeccionando las técnicas y buscar datos de mejor calidad para  
231 fortalecer futuros desarrollos

232

233 **Bibliografía**

- 234 [1] Cooper RJ, Schriger DL, Flaherty HL, Lin EJ, Hubbell KA. Efecto de los signos vitales en  
235 las decisiones de triaje. Ann Emerg Med. 2002 Mar; 39 (3):223-32. [ [PubMed](#) ]
- 236 [2] MÉNDEZ ORJUELA, Lida. ADVISE-BD: Modelo de detección de anomalías clínicas usando  
237 datos de los signos vitales de pacientes de UCIP de una cohorte del Hospital Militar Central de  
238 Colombia, mediante el uso de técnicas de aprendizaje automático. [[en línea](#)]. Universidad de los  
239 Andes, 2022153.
- 240 [3] Clinica Sagrado Corazon, *Protocolo de Monitoreo No Invasivo de Signos Vitales*, versión 002,  
241 abril 2013, código M-HO-G-010, 11 pp.
- 242 [4] Mayo Clinic, "Heart rate: What's normal?", *Mayo Clinic*, 2023. [Online]. Available:  
243 <https://www.mayoclinic.org/healthy-lifestyle/fitness/expert-answers/heart-rate/faq-20057979>
- 244 [5] J. A. Floras et al., "Variabilidad de la presión arterial y morbilidad: un análisis clínico,"  
245 Rev. Esp. Cardiol., vol. 52, no. 12, pp. 1017-1031, 1999
- 246 [6] McIntyre L.A., Fergusson D.A., Hébert P.C., Moher D., Hutchinson J.S., "Prolonged  
247 therapeutic hypothermia after traumatic brain injury in adults. A systematic review," JAMA, vol.  
248 289, no. 22, pp. 2992–2999, 2003.
- 249 [7] E. J. Topol, "Deep Medicine: How Artificial Intelligence Can Make Healthcare Human Again,"  
250 in NCBI Bookshelf, National Center for Biotechnology Information (US), 2019. [Online].  
251 Available: <https://www.ncbi.nlm.nih.gov/books/NBK482316>. [Accessed: Nov. 25, 2025].
- 252 [8] Maria Bernarda Salazar, "Intro\_data\_2025", notebook de clase, Universidad de Antioquia,  
253 Medellin, 2025.
- 254 [9] G. Mancia et al., "Baroreflex mechanisms in human cardiovascular regulation," Circulation  
255 Research, vol. 116, no. 6, pp. 976–990, 2015. [Online]. Available:  
256 <https://doi.org/10.1161/CIRCRESAHA.115.305374>
- 257 [10] J. B. West, *Respiratory Physiology: The Essentials*, 10th ed. Philadelphia, PA: Wolters  
258 Kluwer, 2015.